

3,120 Methoden: Statistik

Übungsblatt 4: Stichprobenverteilungen und Schätztheorie

Mathis Mörke
Michael Schürle
und Alois Weigand

Universität St.Gallen (HSG)

Herbstsemester 2024

Aufgabe 1

In einem grossen Produktionsunternehmen beträgt die **durchschnittliche Anzahl geleisteter Überstunden 62** pro Jahr mit einer zugehörigen **Standardabweichung von 15** Stunden. Wie gross ist die Wahrscheinlichkeit, dass in einer zufällig gezogenen Stichprobe mit der Grösse $n = 36$

1. die **durchschnittliche Überstundenzahl** kleiner 65 ist?
2. die durchschnittliche Überstundenzahl zwischen 55 und 65 liegt?
3. die durchschnittliche Überstundenzahl kleiner als 60 ist?

Refresher Aufgabe 1

- ▶ Gesucht: $P(x_1 \leq \bar{X} \leq x_2)$
 - ▶ Schritt 1: Standardisieren: $Z = \frac{\bar{X} - E(\bar{X})}{\sigma_{\bar{X}}}$
 - ▶ Schritt 2: Berechne z-Werte
 - ▶ Schritt 3: Finde den entsprechenden Wert in der Tabelle
- ▶ Warum die Standardnormalverteilung?
⇒ Zentraler Grenzwertsatz

Refresher Aufgabe 1

► Zentraler Grenzwertsatz (Intuition)

- Verteilung des arithmetischen Mittelwerts von n unabhängig identisch (wie die Grundgesamtheit) verteilten Zufallsvariablen X_i strebt mit wachsendem Stichprobenumfang n gegen eine Normalverteilung mit dem Erwartungswert μ und der Varianz σ^2/n
- für jede Verteilung der Grundgesamtheit kann die Verteilung des Mittelwertes durch die Normalverteilung angenähert werden ⇒ gilt wenn: Stichprobengrösse ausreichend gross ($n \geq 30$).

Refresher Aufgabe 1

► Zentraler Grenzwertsatz

- ▶ X_1, X_2, \dots, X_n seien stochastisch unabhängige Zufallsvariablen
 - ⇒ gleiche Verteilung (identisch)
 - ⇒ gleicher Erwartungswert μ , gleiche Varianz σ^2
 - ⇒ **Idee:** Zufallsstichprobe mit Zurücklegen
- ▶ Dann: Zufallsvariable $Z = \frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\frac{\sigma}{\sqrt{n}}}$
ist näherungsweise standardnormalverteilt (für $n \geq 30$)
- ▶ Achtung: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ist auch eine Zufallsvariable mit der Realisation \bar{x} aus den Stichprobenwerten $x_1, x_2, x_3, \dots, x_n$

Refresher Aufgabe 1

- ▶ **Zentraler Grenzwertsatz**
- ▶ Warum Zufallsvariable $Z = \frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\frac{\sigma}{\sqrt{n}}}$? $\rightarrow Z = \frac{\bar{X} - E(\bar{X})}{\sigma_{\bar{X}}}$
 - ▶ Erwartungswert $E(\bar{X})$
 $\Rightarrow E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \frac{1}{n} \cdot n\mu = \mu$
 - ▶ Varianz $\sigma_{\bar{X}}^2$
 $\Rightarrow Var(\bar{X}) = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$
 - ▶ Standardabweichung von \bar{X} ist dann $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$

Aufgabe 1

1. durchschnittliche Überstundenzahl kleiner 65

⇒ Mittelwert $\mu = 62$, Standardabweichung $\sigma = 15$,
Stichprobengröße $n = 36$

- ▶ $P(\bar{X} < 65) = P(Z < \frac{65-62}{2.5}) = P(Z < 1.20)$
- ▶ Was brauchen wir?

- ▶ $Z = \frac{\bar{X}-\mu}{\sigma_{\bar{X}}} = \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \Rightarrow z = \frac{65-\mu}{\frac{\sigma}{\sqrt{n}}}$
- ▶ $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{15}{\sqrt{36}} = \frac{15}{6} = 2.5$

Aufgabe 1

1. durchschnittliche Überstundenzahl kleiner 65

⇒ Mittelwert $\mu = 62$, Standardabweichung $\sigma = 15$,
Stichprobengröße $n = 36$

- ▶ $P(\bar{X} < 65) = P(Z < \frac{65-62}{2.5}) = P(Z < 1.20)$
- ▶ für $z = 1.20 \Rightarrow 0.8849$

Aufgabe 1

2. durchschnittliche Überstundenzahl zwischen 55 und 65

⇒ Mittelwert $\mu = 62$, Standardabweichung $\sigma = 15$,
Stichprobengröße $n = 36$

► $P(55 < \bar{X} < 65) = P\left(\frac{55-62}{2.5} < Z < \frac{65-62}{2.5}\right)$

⇒ $P(-2.80 < Z < 1.20)$

► Was brauchen wir?

► $Z = \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}}$

► $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{15}{\sqrt{36}} = \frac{15}{6} = 2.5$

Aufgabe 1

2. durchschnittliche Überstundenzahl zwischen 55 und 65

⇒ Mittelwert $\mu = 62$, Standardabweichung $\sigma = 15$,

Stichprobengröße $n = 36$

► $P(55 < \bar{X} < 65) = P\left(\frac{55-62}{2.5} < Z < \frac{65-62}{2.5}\right)$
⇒ $P(-2.80 < Z < 1.20)$

Tabelle: für $z = 2.80 \Rightarrow 0.9974$

Tabelle: für $z = 1.20 \Rightarrow 0.8849$

$$\Rightarrow P(-2.80 < Z < 1.20) = 0.8849 - (1 - 0.9974) = \\ 0.8849 - 0.0026 = 0.8823$$

► Fläche unter Dichtefunktion ist immer 1!

Aufgabe 1

3. durchschnittliche Überstundenzahl kleiner 60

⇒ Mittelwert $\mu = 62$, Standardabweichung $\sigma = 15$,
Stichprobengröße $n = 36$

► $P(\bar{X} < 60) = P(Z < \frac{60-62}{2.5}) = P(Z < -0.80)$

► Was brauchen wir?

► $Z = \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}}$

► $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{15}{\sqrt{36}} = \frac{15}{6} = 2.5$

Aufgabe 1

3. durchschnittliche Überstundenzahl kleiner 60

⇒ Mittelwert $\mu = 62$, Standardabweichung $\sigma = 15$,
Stichprobengröße $n = 36$

- ▶ $P(\bar{X} < 60) = P(Z < \frac{60-62}{2.5}) = P(Z < -0.80)$
- ▶ aus Tabelle: für $z = 0.80 \Rightarrow 0.7881$
- ▶ $P(\bar{X} < 60) = P(Z < \frac{60-62}{2.5}) = P(Z < -0.80) = 1 - 0.7881 = 0.2119$

Aufgabe 2

Die **durchschnittliche Verweildauer für einen Spitalaufenthalt betrage 4.9 Tage** bei einer zugehörigen **Standardabweichung von 3.5 Tagen**. Angenommen es werde eine **Stichprobe von 50 Patienten** gezogen, wie gross ist dann die **Wahrscheinlichkeit, dass die durchschnittliche Verweildauer für diese Gruppe nicht mehr als 5.7 Tage beträgt?**

Aufgabe 2

- ▶ durchschnittliche Verweildauer nicht mehr als 5.7 Tage

⇒ Mittelwert $\mu = 4.9$, Standardabweichung $\sigma = 3.5$,
Stichprobengröße $n = 50$

$n = 50 \Rightarrow$ Stichprobenmittelwert \bar{x} kann als normalverteilt
angenommen werden (Zentraler Grenzwertsatz)

- ▶ $P(\bar{X} < 5.7) = P(Z < \frac{5.7 - 4.9}{0.495}) = P(Z < 1.62)$
- ▶ Was brauchen wir?
 - ▶ $Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$
 - ▶ $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{3.5}{\sqrt{50}} = 0.495$

Aufgabe 2

- ▶ **durchschnittliche Verweildauer nicht mehr als 5.7 Tage**
⇒ Mittelwert $\mu = 4.9$, Standardabweichung $\sigma = 3.5$,
Stichprobengröße $n = 50$
- ▶ $P(\bar{X} < 5.7) = P(Z < \frac{5.7 - 4.9}{0.495}) = P(Z < 1.62) = 0.9474$

Recap: Verteilung des Stichprobenmittelwerts

► Verteilung des Stichprobenmittelwerts \bar{X}

- bei grossem Stichprobenumfang n :

$$E(\bar{X}) = \mu$$

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

\bar{X} annähernd normalverteilt

- $\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$ ist standardnormalverteilt:

$$Prob(-z < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < +z) = F_{Sn}(z) - F_{Sn}(-z) = D(z)$$

Aufgabe 3

Es wird geschätzt, dass 17% der Besitzer von Aktienfonds-Anteilen Rentner seien ($\pi = 0.17$). Angenommen es wurde eine zufällige Stichprobe von $n = 400$ Aktienfonds-Besitzern gezogen:

1. Geben Sie den **Erwartungswert für den Anteil p** der Rentner in der Stichprobe an. Geben Sie ferner die **Standardabweichung für den Anteil p** an.
2. Wie gross ist die Wahrscheinlichkeit, **dass mind. 20% der in der Stichprobe enthaltenen Personen Rentner sind?**
3. Wie gross ist die **Wahrscheinlichkeit, dass sich der Anteil Rentner zwischen 15% und 25% bewegt?**

Refresher Aufgabe 3

► Stichprobenanteilswert $P = \frac{X}{n} = \frac{1}{n} \sum_{i=1}^n X_i$

► Was wissen wir:

- X_1, X_2, \dots, X_n sind stochastisch unabhängige Bernoulli-Experimente
- Anzahl der Erfolge X durch Addition
- jedes X_i : 1 für Erfolg und 0 für Misserfolg
- mit Zurücklegen!!
- gleicher Erwartungswert $E(X_i) = \pi$
- gleiche Varianz $\text{Var}(X_i) = \pi(1 - \pi)$

► Für die Zufallsvariable $X = \sum_{i=1}^n X_i$:

$$\Rightarrow E(X) = n \cdot \pi$$

$$\Rightarrow \text{Var}(X) = n \cdot \pi \cdot (1 - \pi)$$

⇒ siehe Binomialverteilung

Refresher Aufgabe 3

► Zentraler Grenzwertsatz

- für Zufallsvariable $Z = \frac{P - E(P)}{\sigma_P}$
- mit Anteilswert $P = \frac{X}{n} = \frac{1}{n} \sum_{i=1}^n X_i$

$$\Rightarrow E(P) = \frac{1}{n} E(X) = \frac{1}{n} \cdot n \cdot \pi = \pi$$

$$\Rightarrow \text{Varianz } \sigma_P^2 = \text{Var}(P) = \text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) = \frac{1}{n^2} \cdot n \cdot \pi \cdot (1 - \pi) = \frac{\pi(1-\pi)}{n}$$

$$\Rightarrow \text{Standardabweichung } \sigma_P = \sqrt{\frac{\pi(1-\pi)}{n}}$$

Refresher Aufgabe 3

► Zentraler Grenzwertsatz

- ▶ X_1, X_2, \dots, X_n seien stochastisch unabhängige Zufallsvariablen
 - ⇒ gleiche Verteilung
 - ⇒ gleicher Erwartungswert und gleiche Varianz
- ▶ Dann ist die Zufallsvariable $Z = \frac{P - E(P)}{\sigma_P} = \frac{P - \pi}{\sqrt{\frac{\pi(1-\pi)}{n}}}$ näherungsweise standardnormalverteilt
- ▶ wenn gilt: $n\pi \geq 5$ und $n(1 - \pi) \geq 5$ (Weiers)

Aufgabe 3

Es wurde geschätzt, dass 17% der Besitzer von Aktienfonds-Anteilen Rentner seien ($\pi = 0.17$). Angenommen es wurde eine zufällige Stichprobe von $n = 400$ Aktienfonds-Besitzern gezogen:

1. Geben Sie den Erwartungswert für den Anteil p der Rentner in der Stichprobe an. Geben Sie ferner die Standardabweichung für den Anteil p an.
2. Wie gross ist die Wahrscheinlichkeit, dass mind. 20% der in der Stichprobe enthaltenen Personen Rentner sind?
3. Wie gross ist die Wahrscheinlichkeit, dass sich der Anteil Rentner zwischen 15% und 25% bewegt?

Aufgabe 3

1. Erwartungswert und Standardabweichung für Anteil p ?

- ▶ Erwartungswert $E(P) = \pi = 0.17$
- ▶ Standardabweichung $\sigma_P = \sqrt{\frac{\pi(1-\pi)}{n}} = \sqrt{\frac{0.17(1-0.17)}{400}} = 0.0188$

Aufgabe 3

2. Wahrscheinlichkeit, dass mind. 20% der in der Stichprobe enthaltenen Personen Rentner sind

- ▶ Es gilt $n\pi = 68 \geq 5$ und $n(1 - \pi) = 332 \geq 5$
 $\Rightarrow Z = \frac{P - E(P)}{\sigma_P} = \frac{P - \pi}{\sqrt{\frac{\pi(1-\pi)}{n}}}$ als normalverteilt angenommen
- ▶ $P(p \geq 0.20) = P(z \geq \frac{0.20 - 0.17}{0.0188}) = P(z \geq 1.60) = 1 - 0.9452 = 0.0548$
- ▶ aus Tabelle: für $z = 1.60 \Rightarrow 0.9452$

Aufgabe 3

3. Wahrscheinlichkeit, dass sich der Anteil Rentner zwischen 15% und 25% bewegt

$$\begin{aligned}\blacktriangleright P(0.15 \leq p \leq 0.25) &= P\left(\frac{0.15-0.17}{0.0188} \leq z \leq \frac{0.25-0.17}{0.0188}\right) = \\ P(0.15 \leq p \leq 0.25) &= P(-1.06 \leq z \leq 4.26) = \\ 1 - (1 - 0.8554) &= 0.8554\end{aligned}$$

Recap: Grenzwertsätze

- ▶ Annahme: Zufallsvariable X_i stochastisch unabhängig \Rightarrow Wahrscheinlichkeiten bleiben gleich
... oder Mit Zurücklegen!!
- ▶ Ohne Zurücklegen bei endlicher Grundgesamtheit
 \Rightarrow **Korrekturfaktor (siehe Weiers)**

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}$$

$$\sigma_P = \sqrt{\frac{\pi(1-\pi)}{n}} \times \sqrt{\frac{N-n}{N-1}}$$

- ▶ für Stichprobengröße n und N Größe der Grundgesamtheit
 \Rightarrow vernachlässigbar wenn $n/N < 0.05$ (siehe Weiers)

Recap: Verteilung des Stichprobenanteilswerts

► Verteilung des Stichprobenanteilswerts P

- wenn: $n\pi \geq 5$ und $n(1 - \pi) \geq 5$ (Weiers):

$$E(P) = \pi$$

$$\sigma_P = \sqrt{\frac{\pi(1-\pi)}{n}}$$

p annähernd normalverteilt

- $Z = \frac{P - E(P)}{\sigma_P} = \frac{P - \pi}{\sqrt{\frac{\pi(1-\pi)}{n}}}$ ist standardnormalverteilt:

$$Prob(-z < \frac{P - \pi}{\sqrt{\frac{\pi(1-\pi)}{n}}} < +z) = F_{Sn}(z) - F_{Sn}(-z) = D(z)$$

Aufgabe 4

Eine Bierbrauerei füllt ihre 0.5 Liter Bügelflaschen maschinell ab. Wegen des näherungsweise normalverteilten Abfüllfehlers nach $N(\mu = 0, \sigma^2 = 3.84\text{cl}^2)$ ist die Maschine auf 50.2cl eingestellt. Von den verwendeten Flaschen seien (aufgrund einer im Laugengehalt falsch eingestellten Waschmaschine) 4% der Gummidichtungen der Verschlüsse porös. Ein Kunde lässt sich 1 Palette (40 Kisten zu je 15 Flaschen) schicken.

1. Geben Sie ein 95%-**Prognoseintervall** (resp. Wahrscheinlichkeitsintervall) **für den durchschnittlichen Flascheninhalt und den Gesamtinhalt** der Sendung an,
2. sowie **entsprechende Intervalle für den Anteil und die Gesamtzahl der Flaschen mit porösen Gummidichtungen**.
3. Wie gross ist die Wahrscheinlichkeit, dass der durchschnittliche Flascheninhalt weniger als 0.5 Liter ist?

Aufgabe 4

1) 95%-Wahrscheinlichkeitsintervall für durchschnittl. Flascheninhalt (und Gesamtinhalt)

- ▶ Was wissen wir?
 - ▶ $1 - \alpha = 95\% \Rightarrow \alpha = 0.05$, aber zweiseitiger Test
 \Rightarrow für $\alpha/2 = 0.025$ bekommen wir z-Wert von 1.96
($1-0.025=0.975$)
 - ▶ Stichprobe $n = 600$ (40 Kisten zu je 15 Flaschen)
 - ▶ Mittelwert $\mu = 50.2\text{cl}$ und Varianz $\sigma^2 = 3.84\text{cl}^2$
 - ▶ Standardabweichung $\sigma_{\bar{x}} = \sqrt{\frac{3.84}{600}} = 0.08$

Aufgabe 4

1) 95%-Wahrscheinlichkeitsintervall für durchschnittl. Flascheninhalt (und Gesamteinheit)

- Direkter Schluss von Grundgesamtheit auf Stichprobe

$$P\left(\mu - z \cdot \sqrt{\frac{\sigma^2}{n}} < \bar{X} < \mu + z \cdot \sqrt{\frac{\sigma^2}{n}}\right) = 0.95$$

- einsetzen:

$$P\left(50.2 - 1.96 \cdot \sqrt{\frac{3.84}{600}} < \bar{X} < 50.2 + 1.96 \cdot \sqrt{\frac{3.84}{600}}\right) = 0.95$$

⇒ 95%-Wahrscheinlichkeitsintervall zwischen 50.04 und 50.36

- Mit 95% Wahrscheinlichkeit liegt der durchschnittliche Flascheninhalt der Stichprobe zwischen 50.04 und 50.36.

Aufgabe 4

1) 95%-Wahrscheinlichkeitsintervall für durchschnittl. Flascheninhalt (und Gesamtinhalt)

- ▶ Mit Wahrscheinlichkeit von 95% liegt der durchschnittliche Flascheninhalt der Stichprobe zwischen 50.04 und 50.36.
- ▶ Für Gesamtinhalt ($n\bar{X}$): Intervallgrenzen $50.04 \cdot 600$ und $50.36 \cdot 600$
⇒ mit 95% ist der Gesamtinhalt zwischen 30024 und 30216 cl
... oder zwischen 300.24 und 302.16 liter ($1cl = 0.01l$)

Aufgabe 4

2) ... Intervall für Anteil (und Gesamtzahl) der Flaschen mit porösen Gummidichtungen

- ▶ Was wissen wir?
 - ▶ $1 - \alpha = 95\% \Rightarrow \alpha = 0.05$, aber zweiseitiger Test
⇒ für $\alpha/2 = 0.025$ bekommen wir z-Wert von 1.96
($1-0.025=0.975$)
 - ▶ Stichprobe $n = 600$ (40 Kisten zu je 15 Flaschen)
 - ▶ jetzt: **Anteilswert** $\pi = 0.04$ in Grundgesamtheit
⇒ selbe Logik

Aufgabe 4

2) ... Intervall für Anteil (und Gesamtzahl) der Flaschen mit porösen Gummidichtungen

- Direkter Schluss von Grundgesamtheit auf Stichprobe

$$P(\pi - z \cdot \sqrt{\frac{\pi(1-\pi)}{n}} < P < \pi + z \cdot \sqrt{\frac{\pi(1-\pi)}{n}}) = 0.95$$

$$\text{► } P(0.04 - 1.96 \cdot \sqrt{\frac{0.04 \cdot 0.96}{600}} < P < 0.04 + 1.96 \cdot \sqrt{\frac{0.04 \cdot 0.96}{600}}) = 0.95$$

- 95%-Wahrscheinlichkeitsintervall zwischen 0.02432 und 0.05568 (also zwischen 2.4% und 5.6%)
- für nP : zwischen $600 \cdot 0.02432 = 14.59$ und $600 \cdot 0.05568 = 33.41$ Flaschen (also zwischen 14 und 34 Flaschen)

Aufgabe 4

3. Wahrscheinlichkeit, dass durchschnittlicher Flascheninhalt $< 50\text{cl}$?

- ▶ $P(\bar{X} < 50) = P\left(\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} < \frac{50-50.2}{0.08}\right)$
 $\Rightarrow z = -0.2/0.08 = -2.5$
 \Rightarrow für $z = 2.5 \Rightarrow 0.9938$ aus Tabelle
 \Rightarrow aber: $P(Z > 2.5) = 1 - 0.9938 = 0.0062$

- ▶ Kontrolle: Wir wissen dass nur ein Anteil von 5% der Durchschnitte ausserhalb des Intervalls [50.04; 50.36] liegt

Aufgabe 5

In einer einfachen Stichprobe von 15 HSG-Studenten wurde die Anzahl ausgelassener Vorlesungstage im letzten Monat ermittelt. Die Stichprobe ergab folgendes Ergebnis:

{0, 3, 8, 1, 3, 0, 1, 2, 1, 0, 4, 5, 2, 1, 3}

1. Ermitteln Sie eine **Schätzung für μ , dem Mittelwert** der ausgelassenen Vorlesungstage eines HSG-Studenten.
2. Geben Sie eine **Schätzung für σ^2 (Varianz)** an.

Aufgabe 5

- ▶ **Gesucht:** Mittelwert μ der Grundgesamtheit
- ▶ Zufallsvariable X : ausgelassene Vorlesungstage
 - ⇒ Zufallsstichprobe von $n = 15$ Studenten
 - ⇒ beobachteten Ausprägungen x_1, x_2, \dots, x_{15}
- ▶ Schätzung $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^{15} x_i$
- ▶ $\bar{x} = \frac{\sum_{i=1}^{15} x_i}{n} = \frac{34}{15} = 2.267$

Aufgabe 5

► Warum $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ für μ ?

1. Merkmalswerte x_1, x_2, \dots, x_n als Realisationen von Zufallsvariablen $X_1, X_2, \dots, X_n \Rightarrow$ Zufallsstichprobe als Zufallsexperiment
2. Stichprobenmittelwert \bar{x} als Realisation der Zufallsvariable $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
3. alle X_i sind identisch und unabhängig mit $E(X_i) = \mu$ und $Var(X_i) = \sigma^2$ (mit Zurücklegen)
4. $E(\hat{\mu}) = E(\bar{X}) = E\left(\frac{1}{n} \sum_i^n X_i\right) = \frac{1}{n} \sum_i^n E(X_i) = \frac{1}{n} n\mu = \mu$

Aufgabe 5

- ▶ **Warum** $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ **für** μ ?
- ▶ $E(\hat{\mu}) = E(\bar{X}) = E\left(\frac{1}{n} \sum_i^n X_i\right) = \frac{1}{n} \sum_i^n E(X_i) = \frac{1}{n} n\mu = \mu$
- ▶ **Erwartungstreuer Schätzer** \Rightarrow im Durchschnitt trifft der Schätzer den gesuchten Wert

Aufgabe 5

► Gesucht: Varianz σ^2 der Grundgesamtheit

► Stichprobenvarianz $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$

... oder umgeformt: $S^2 = \frac{n \sum_{i=1}^n X_i^2 - (\sum_{i=1}^n X_i)^2}{n(n-1)}$

► $s^2 = \frac{n \sum x_i^2 - (\sum x_i)^2}{n(n-1)} = \frac{15(144) - 34^2}{15(15-1)} = 4.781$

Aufgabe 5

- **Warum** $\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ **für** σ^2 ?

$\Rightarrow \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ als Schätzfunktion nicht erwartungstreu

- Intuition:

$$\begin{aligned} E\left(\frac{1}{n} \sum (X_i - \bar{X})^2\right) &= E\left(\frac{1}{n} \sum X_i^2 - \frac{2}{n} \bar{X} \sum X_i + \frac{1}{n} \sum \bar{X}^2\right) \\ &= E\left(\frac{1}{n} \sum X_i^2 - \frac{2}{n} \bar{X} n \bar{X} + \frac{1}{n} n \bar{X}^2\right) = \frac{1}{n} (\sum E(X_i^2) - n E(\bar{X}^2)) \\ &= \frac{1}{n} (n(\sigma^2 + \mu^2) - n(\sigma_{\bar{X}}^2 + \mu^2)) = \frac{1}{n} (n\sigma^2 + n\mu^2 - n\frac{\sigma^2}{n} - n\mu^2) \\ &= \frac{1}{n} (n-1)\sigma^2 = \frac{n-1}{n}\sigma^2 \end{aligned}$$

- Es gilt: $\sigma^2 = E(X_i^2) - \mu^2 \Rightarrow E(X_i^2) = \sigma^2 + \mu^2$

Aufgabe 5

- ▶ **Warum** $\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ **für** σ^2 ?
- ▶ $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ als Schätzfunktion nicht erwartungstreu, da
 $E\left(\frac{1}{n} \sum (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma^2$
- ▶ Für Erwartungstreue: $\hat{\sigma}^2 = \frac{n}{(n-1)} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
⇒ Korrekturfaktor
- ▶ Erwartungstreuer Schätzer: $\hat{\sigma}^2 = S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$
⇒ $E(S^2) = \sigma^2$
⇒ im Durchschnitt trifft der Schätzer den gesuchten Wert

Recap: Punktschätzer

- ▶ Stichprobenmittelwert, -anteilswert, und -varianz als Schätzfunktionen für den Mittelwert, Anteilswert, und die Varianz in der Grundgesamtheit
 - ▶ $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ für μ
 - ▶ $\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ für σ^2
 - ▶ Anteilswert p für π
- ▶ Werte der Schätzfunktionen hängen von den zufällig gezogenen Stichprobenelementen ab
⇒ **Stichprobenverteilung** mit Erwartungswert und Varianz.
- ▶ Im Durchschnitt entspricht der Schätzer dem (unbekannten) wahren Wert in der Grundgesamtheit (über den wir eine Aussage treffen wollen)

Refresher: Intervallschätzung (zweiseitig)

► Bsp: Stichprobenmittelwert

$$\text{Prob}\left(-z < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < +z\right) = F_{S_n}(z) - F_{S_n}(-z) = D(z)$$

- durch umformen: Intervall um Stichprobenmittelwert

$$\text{Prob}\left(\mu - z \cdot \frac{\sigma}{\sqrt{n}} < \bar{X} < \mu + z \cdot \frac{\sigma}{\sqrt{n}}\right) = F_{S_n}(z) - F_{S_n}(-z) = D(z)$$

- mit welcher Wahrscheinlichkeit ein Stichprobenmittelwert in ein vorher bestimmtes Intervall fällt
- Annahme: $\mu, \sigma, n, D(z)$ bekannt \Rightarrow berechne z

Refresher: Intervallschätzung (zweiseitig)

► Schluss von Stichprobe auf Grundgesamtheit

- $\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$ standardnormalverteilt

$$Prob\left(-z < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < +z\right) = F_{S_n}(z) - F_{S_n}(-z)$$

- durch umformen: Intervall um μ

$$Prob\left(\bar{X} - z \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z \cdot \frac{\sigma}{\sqrt{n}}\right) = F_{S_n}(z) - F_{S_n}(-z) = 1 - \alpha$$

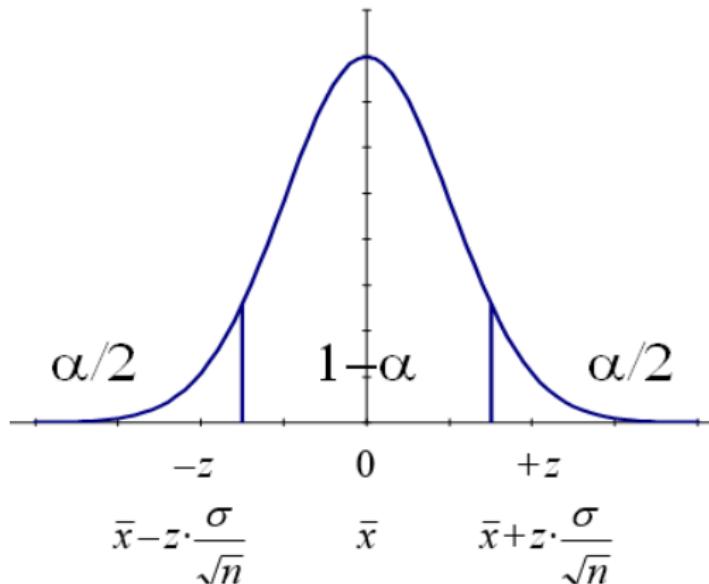
- Konfidenzwahrscheinlichkeit $1 - \alpha$
- Irrtumswahrscheinlichkeit α

Refresher: Intervallschätzung (zweiseitig)

$$\text{Prob}(\bar{X} - z \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z \cdot \frac{\sigma}{\sqrt{n}}) = 1 - \alpha$$

- ▶ Konfidenzwahrscheinlichkeit $1 - \alpha$: wie sehr man darauf vertraut, dass der unbekannte Wert μ im **Konfidenzintervall** liegt
- ▶ Irrtumswahrscheinlichkeit α : wie oft man sich im Mittel irrt
- ▶ α und $1 - \alpha$ vorgegeben
⇒ Anspruch an Genauigkeit der Intervallschätzung
- ▶ bekannt: \bar{x} , σ (oder S aus der Stichprobe), n , α ⇒ berechne z

Refresher: Intervallschätzung (zweiseitig)



Refresher: Intervallschätzung (zweiseitig)

- ▶ **Fall 1: Grundgesamtheit normalverteilt und σ bekannt:**

$$\Rightarrow z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

$$\Rightarrow \bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

- ▶ **Fall 2: Grundgesamtheit beliebig, σ bekannt, $n \geq 30$:**

$$\Rightarrow z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

$$\Rightarrow \bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Refresher: Intervallschätzung (zweiseitig)

- **Fall 3: Grundgesamtheit beliebig, σ unbekannt, $n \geq 30$:**

$$\Rightarrow z = \frac{\bar{x} - \mu}{s/\sqrt{n}} \sim N(0, 1)$$

$$\Rightarrow \bar{x} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$$

$$\Rightarrow s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **Fall 4: Grundgesamtheit normalverteilt, σ unbekannt, $n < 30$:**

$$\Rightarrow t = \frac{\bar{x} - \mu}{s/\sqrt{n}} \sim t_{n-1} \text{ mit } n-1 \text{ Freiheitsgraden}$$

$$\Rightarrow \bar{x} \pm t_{\alpha/2}^{n-1} \cdot \frac{s}{\sqrt{n}}$$

$$\Rightarrow s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Refresher: Intervallschätzung (zweiseitig)

- ▶ Kleine Anmerkung:
 - ▶ falls Grundgesamtheit N endlich und $n/N \geq 0.05$:
 - ⇒ Ohne Zurücklegen angenommen
 - ⇒ Korrekturfaktor $\frac{N-n}{N-1}$ bei Standardfehlern $\sigma_{\bar{X}}$ oder σ_P
 - ⇒ In Vorlesung nicht weiter behandelt.

Aufgabe 6

Von 1000 Bachelor-Studenten werden 37 zufällig ausgewählte Studenten nach ihrem Alter befragt. Es ergibt sich ein Durchschnittsalter von $\bar{x} = 23$ Jahren mit einer Standardabweichung von 0.6 Jahren. Bestimmen Sie ein 95%-Konfidenzintervall für das Durchschnittsalter.

Anmerkung: Wir interessieren uns für das Durchschnittsalter aller Bachelor Studenten der Grundgesamtheit (mit $N = 1000$)

Aufgabe 6

- ▶ **Gesucht: 95%-Konfidenzintervall für das Durchschnittsalter**
- ▶ Was wissen wir?
 - ▶ $N = 1000$ mit Stichprobe $n = 37$
 - ▶ aus Stichprobe: $\bar{x} = 23$ und $s = 0.6$
 - ▶ $n/N = 37/1000 = 0.037 < 5\%$
⇒ auf Korrekturfaktor kann verzichtet werden
 - ▶ Varianz σ unbekannt: $\hat{\sigma}_{\bar{X}} = \frac{s}{\sqrt{n}}$
 - ▶ Verteilung der Grundgesamtheit unbekannt, aber $n > 30$

Aufgabe 6

- ▶ Gesucht: 95%-Konfidenzintervall für das Durchschnittsalter
- ▶ Konfidenzintervall für unbekanntes Durchschnittsalter μ
$$\Rightarrow \bar{x} \pm z_{\alpha/2} \cdot \frac{\hat{\sigma}}{\sqrt{n}}$$
$$Prob(\bar{X} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}) = 1 - \alpha$$
- ▶ $\hat{\sigma}_{\bar{X}} = \frac{s}{\sqrt{n}} = \frac{0.6}{\sqrt{37}} = 0.099$
- ▶ $z = 1.96$ für $\alpha/2 = 0.025$ (zweiseitig)
- ▶ einsetzen:
- ▶ $P(23 - 1.96 \cdot 0.099 < \mu < 23 + 1.96 \cdot 0.099) = 0.95$
 \Rightarrow Konfidenzintervall zwischen 22.806 und 23.194

Aufgabe 7

Aus den (angenommenen) 20000 Studierenden der Zürcher Universität werden 600 für eine Befragung zufällig ausgewählt. In der Stichprobe gaben 360 Studierende an, ein festes Natel-Abo zu besitzen.

1. Geben Sie einen erwartungstreuen Schätzwert für den Anteil der Natel-Telefonierer (mit Abo) der ZH-Uni an.
2. Ermitteln Sie für den Anteil und die Anzahl der Natel-Abo-Besitzer in der Grundgesamtheit ein 95%-Konfidenzintervall und interpretieren Sie dieses.

Aufgabe 7

- ▶ **Erwartungstreuer Schätzer für Anteilswert**
- ▶ Stichprobenanteilswert: Anteil des Erfolgs x in einer Stichprobe von n Versuchen
- ▶ $\hat{\pi} = p = \frac{360}{600} = 0.6$
- ▶ Warum Stichprobenanteilswert? \Rightarrow Erwartungstreue
 - ▶ p als Realisation von $P = \frac{X}{n} = \frac{1}{n} \sum_{i=1}^n X_i$
 - ▶ Bernoulli-Zufallsvariable X_i mit $E(X_i) = \pi$
 - ▶ Für $X = \sum_{i=1}^n X_i$ gilt $E(X) = n \times \pi$
 $\Rightarrow E(P) = \frac{1}{n} E(X) = \frac{1}{n} \times n \times \pi = \pi$

Aufgabe 7

- ▶ 95%-Konfidenzintervall für Anteilswert und Anzahl der Abo-Besitzer
- ▶ $x = np = 360 \geq 5$ und $n(1 - p) = 240 \geq 5$
⇒ Verteilung durch Normalverteilung approximiert
- ▶ $n/N = 600/20000 = 0.03 < 5\%$
⇒ Korrekturfaktor vernachlässigbar
- ▶ $\sigma_P = \sqrt{\frac{\pi(1-\pi)}{n}} \Rightarrow s_P = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.6(0.4)}{600}} = 0.02$
- ▶ Konfidenzwahrscheinlichkeit von 95% ⇒ $\alpha = 5\%$
- ▶ zweiseitig z-Wert für $\alpha/2 = 0.025$ entspricht 1.96

Aufgabe 7

- ▶ 95%-Konfidenzintervall für Anteilswert und Anzahl der Abo-Besitzer
- ▶ Konfidenzwahrscheinlichkeit von 95% $\Rightarrow \alpha = 5\%$
- ▶ zweiseitig z-Wert für $\alpha/2 = 0.025$ entspricht 1.96
- ▶ $Prob(p - z_{\alpha/2} \cdot \sigma_P \leq \pi \leq p + z_{\alpha/2} \cdot \sigma_P) = 0.95$
- ▶ $Prob(0.6 - 1.96 \cdot 0.02 \leq \pi \leq 0.6 + 1.96 \cdot 0.02) = 0.95$
- ▶ $Prob(0.56 \leq \pi \leq 0.64) = 0.95$

Aufgabe 7

- ▶ 95%-Konfidenzintervall für Anteilswert und Anzahl der Abo-Besitzer
- ▶ Konfidenzintervall $\text{Prob}(0.56 \leq \pi \leq 0.64) = 0.95$
- ▶ $N = 20000$ Studenten (davon $\pi = 0.6$ (oder 60%))
⇒ Konfidenzintervall für Anzahl der Abo-Besitzer $N\pi$
⇒ $\text{Prob}(0.56 \cdot 20000 \leq N\pi \leq 0.64 \cdot 20000) = 0.95$
⇒ $\text{Prob}(11200 \leq N\pi \leq 12800) = 0.95$